


Introduction to Data Concepts

START COURSE

IBM SkillsBuild



In this course, you'll become familiar with fundamental data concepts such as types of data, big data, the typical steps in the data analytics process, and data visualization.

Select **START COURSE** to begin, or check out the course content in detail [here](#).

Los datos son herramientas para resolver problemas. Los analistas de datos interpretan la información, siguiendo unos pasos que incluye la recopilación, limpieza y transformación de los datos. Su objetivo es extraer información valiosa. El propósito es aprovechar estos conocimientos para facilitar decisiones más concretas y resolver problemas de manera efectiva.

Se calcula que diariamente se producen 2,5 quintillones de bytes de datos, que equivale a 1 seguido de 18 ceros. Entre las cifras relacionadas con la creación de datos, se observa que las personas realizan 3 mil millones de minutos de llamadas en Skype, comparten 5 mil millones de videos y fotos en Snapchat, envían 333.2 mil millones de correos electrónicos y gastan 1 millón de USD cada minuto en Internet.

Los datos estructurados son información que se organiza en filas y columnas, como en hojas de cálculo de Microsoft Excel. Los analistas de datos utilizan herramientas como SQL para analizar grandes volúmenes de datos almacenados en múltiples tablas interconectadas. Si se puede agrupar la información según características específicas, se considera que esos grupos son datos estructurados.

Introducción a los Conceptos de Datos

18% COMPLETO

Sobre este módulo

¿Por qué son importantes los datos?

¿Cuántos datos hay?

Los datos pueden ser estructurados o no estructurados

Bases de datos

Piense en los datos como cualitativos o cuantitativos

Quiz

MÓDULO 2: BIG DATA

Sobre este módulo

¿Qué es big data?

Número de cliente	Apellido	Número de teléfono	Fecha de último pedido
00001	Ajay	(555) 678-9012	12-mar-2020
00002	Thompson	(555) 345-6789	14-Ago-2021
00003	Smith	(555) 432-1098	01-Ago-2021
00004	Kim	(555) 665-5443	16-Nov-2021
00005	González	(555) 912-9945	29-Dic-2019
00006	Wangzi	(555) 212-3767	30-junio-2022
00007	Colbert	(555) 866-0922	09-en-2022
00008	Jarrah	(555) 778-1845	12-Sept-2020
00009	Magunusson	(555) 395-7677	14-Abr-2022
00010	Taki	(555) 550-5515	30-Oct-2021

Los datos no estructurados abarcan "todo lo demás" que no tiene un formato definido ni una organización. Se presentan como un conjunto diverso de datos que se almacenan en sus formatos originales. Ejemplos de este tipo de datos incluyen imágenes, textos, publicaciones en redes sociales como tweets, comentarios de clientes, registros médicos y letras de canciones.

La mayoría de las bases de datos se estructuran como bases de datos relacionales, que consisten en múltiples conjuntos de datos o tablas interconectadas. Por ejemplo, una tabla puede contener nombres y direcciones, mientras que otra puede listar propiedades y sus propietarios. Si algunos propietarios también figuran en la tabla de nombres y direcciones, estas tablas pueden vincularse, formando así una base de datos relacional.

Cuantitativo significa que algo es numérico y puedes contarlo. Pensar cantidad - algo que puedes contar (o medir).

Cualitativo significa que algo no es numérico y se puede contar. Pensar calidad – algo que puedes categorizar sobre datos en su lugar.

Los datos cuantitativos pueden ser discreto o continuo.

Los datos cualitativos pueden ser nominal o ordinal.

El big data se refiere a la gran cantidad de datos generados diariamente por personas a través de dispositivos conectados a Internet. Esto incluye mensajes de texto, registros escolares, hábitos de viaje y preferencias de películas, creando un rastro digital de cada usuario.

Los elementos de big data se pueden explicar utilizando cinco características amplias llamadas 5 Vs. Los 5 Vs son Volumen, Variedad, Velocidad, Veracidad, y Valor. Los 5 Vs ayudan a los científicos de datos a dar sentido a lo que están trabajando y se representan en este diagrama.

El análisis descriptivo es el tipo más básico y común de análisis de datos, que responde a la pregunta "¿Qué está sucediendo?". Proporciona una visión general de las tendencias y patrones comerciales utilizando datos históricos y actuales, permitiendo a los analistas obtener información valiosa sobre el pasado y métricas clave de una empresa. Aunque no explica las causas de los hallazgos, ayuda a identificar problemas y áreas para investigar. Ejemplos de datos utilizados incluyen el número de suscriptores, encuestas de satisfacción del cliente, informes de ingresos y datos demográficos de clientes.

El curso está diseñado para ofrecer una comprensión básica de los datos y su análisis. Está estructurado en varios módulos, comenzando con los tipos de datos y su importancia, seguido por una introducción al big data y los tipos de análisis de datos, que incluyen el análisis descriptivo, diagnóstico, predictivo y prescriptivo. El análisis descriptivo proporciona una visión general de las tendencias y patrones actuales, mientras que el análisis diagnóstico busca entender las causas detrás de estos patrones. Cada módulo incluye cuestionarios para evaluar el progreso del estudiante, y el curso culmina con una evaluación final para consolidar el aprendizaje.

El análisis predictivo utiliza datos históricos para hacer pronósticos sobre el futuro, como la probabilidad de eventos, cantidades cuantificables o el tiempo en que ocurrirá algo, mediante modelos predictivos.

El análisis prescriptivo utiliza información de análisis previos para recomendar acciones específicas que aborden problemas o aprovechen tendencias. Su objetivo es guiar decisiones estratégicas y requiere un compromiso significativo de recursos y tecnología avanzada, como aprendizaje automático y algoritmos.

"Esto es 'square one' en el proceso. Este paso consiste en recopilar los datos correctos y los datos suficientes para las preguntas o problemas de los proyectos que queremos investigar.

"Siguiente, no todos los datos que recopile serán útiles, ¡así que es hora de limpiarlos!

La limpieza de datos es el proceso de detectar y corregir registros faltantes o inexactos de un conjunto de datos.

"Una vez que tengo los datos relevantes y se limpia, es hora de analizar. Este es el paso en el que los analistas de datos pasan alrededor del 20-30% de su tiempo

ETL proporciona la base para análisis de datos y flujos de trabajo de aprendizaje automático. Las organizaciones a menudo usan ETL para:

Extraer datos de sistemas heredados

Limpiar los datos para mejorar la calidad de los datos y establecer la coherencia

Cargar datos en una base de datos de destino


¿De qué sirven los datos si no puede comunicarse al respecto de una manera que la gente entienda? Aquí es donde entran en juego las visualizaciones. Una visualización de datos es una visualización gráfica de información abstracta o compleja. Los analistas de datos utilizan visualizaciones como cuadros, gráficos y mapas por dos razones:

Explorar e interpretar datos durante el análisis para identificar patrones o tendencias

Comunicar resultados y ayudar a las personas a comprender las ideas para tomar decisiones

El cuentacuentos de datos es el proceso de transformar análisis de datos en historias claras y comprensibles para influir en decisiones comerciales. Es una habilidad crucial en el contexto de negocios digitales, ya que ayuda a los tomadores de decisiones a interpretar y conectar los resultados con acciones efectivas.

The screenshot shows a web browser window with the URL `ole03.yourlearning.ibm.com/mod/scorm/player.php?cat=fe40394716012c1040ecc41af60ff0948&a=479¤torg=articulate_rise&scoid=2367&display=popup&m...`. The page title is "Introducción a los Conceptos de Datos". A sidebar on the left lists the course progress, showing 97% completion. The main content area displays a large blue checkmark and the text "Your score 93%". A progress indicator shows "PASANDO 80%". Below the checkmark, there is a "TOMAR DE NUEVO" button with a circular arrow icon. At the bottom, there is a large blue "Continue" button. The sidebar lists the following items: "Es hora de visualizar y contar una historia", "Una visualización temprana", "Cuenta una historia de datos convincente", "Tipos de visualizaciones", "Seleccione el mejor gráfico", "Los datos pueden ser engañosos", "Quiz", "RESUMEN Y EVALUACIÓN FINAL", "¡Has llegado tan lejos!", "Puntos clave para recordar", and "Evaluación final".



En este curso, aprenderá sobre el campo de la ciencia de datos, incluidas las metodologías ampliamente adoptadas y los pasos de un proceso de metodología de ciencia de datos. También

La ciencia de datos es un enfoque que combina:

Método científico

Matemáticas y estadísticas

Programación especializada

Análisis avanzado

Inteligencia artificial (IA)

Narración de historias

Su objetivo es extraer insights accionables a partir de grandes volúmenes de datos digitales ayudando a las empresas a comprender y explicar ideas comerciales ocultas en sus datos

Los datos son considerados una mercancía, y las empresas requieren métodos para procesarlos y descubrir su valor. La ciencia de datos es un proceso científico repetible que, aunque no es mecánico y permite la creatividad, implica pasos específicos como:

Recopilación de datos

Limpieza de datos

Aprendizaje automático

Visualización

La técnica de los 5 Porqués es una herramienta efectiva para la resolución de problemas que consiste en preguntar "¿Por qué?" cinco veces para identificar la causa raíz de un problema. Al hacer cada pregunta, se obtiene una respuesta que guía la siguiente pregunta. Este proceso puede

revelar la causa raíz aunque algunos problemas pueden tener múltiples causas raíces, lo que requiere repetir el método con diferentes secuencias de preguntas

Los analistas de datos recopilan y examinan grandes conjuntos de datos para identificar tendencias y crear visualizaciones que cuentan historias convincentes ayudando a las empresas a tomar decisiones informadas. Por otro lado, los científicos de datos diseñan nuevos procesos para el modelado de datos, utilizando algoritmos, análisis predictivo y estadístico. Poseen habilidades técnicas para organizar datos no estructurados y desarrollar metodologías propias para realizar predicciones basadas en tendencias

una metodología es una estrategia general que guía las actividades en un proceso sin depender de tecnologías o herramientas específicas. ayuda a los científicos de datos un marco para utilizar métodos y procesos en la búsqueda de respuestas o resultados. Al igual que los científicos los científicos de datos requieren una metodología clara para estructurar su trabajo y obtener conclusiones efectivas.

CRISP-DM (Proceso Estándar Cross-Industry para Minería de Datos) es una metodología establecida que guía los esfuerzos de minería de datos y puede ser utilizada por cualquier industria para estructurar proyectos de ciencia de datos. Fundada por el Programa Estratégico Europeo de Investigación en Tecnologías de la Información, CRISP-DM ofrece un enfoque flexible y completo para la ciencia de datos.

La metodología KDD (Knowledge Discovery in Databases) ayuda a las empresas a entender las necesidades y comportamientos de los clientes, así como a predecir tendencias de compra para mantener la competitividad. Aunque es iterativa, permitiendo la integración y transformación de nuevos datos para obtener resultados mejorados, no aborda aspectos modernos como la arquitectura de big data, consideraciones éticas o los diversos roles en equipos de ciencia de datos. El conocimiento adquirido puede reciclarse en el proceso, aumentando su efectividad.

SEMMA es una metodología de ciencia de datos que ayuda a convertir los datos en conocimiento. SEMMA puede ayudar a resolver una variedad de problemas comerciales, como la identificación de fraudes, la retención y rotación de clientes, el marketing de bases de datos, la lealtad del cliente, la segmentación del mercado y el análisis de riesgos.

Cada proyecto de ciencia de datos comienza con la comprensión empresarial, donde el equipo analiza el problema que debe resolverse, apoyado por el patrocinador del negocio. Utilizando pensamiento de diseño, el equipo define el problema, establece objetivos y documenta requisitos. Una vez claro el problema, los científicos de datos eligen un enfoque analítico, como un modelo de regresión logística, para resolverlo. La colaboración continua del patrocinador es crucial para el éxito del proyecto.

Los científicos de datos reciclan datos de diversas fuentes, tanto estructuradas como no estructuradas, para abordar problemas específicos. En la etapa de exploración y preparación de datos, analizan los conjuntos de datos para identificar patrones y relaciones, lo que puede llevar a ajustar hipótesis iniciales. La preparación de datos es crucial y a menudo la etapa más lenta, ya que implica limpiar, combinar y transformar datos para su uso en modelado. Los datos del mundo real suelen requerir ajustes debido a problemas como incompletitud, errores, irrelevancia o

valores atípicos. Para manejar grandes volúmenes de datos, los científicos de datos emplean herramientas y procesos automatizados que facilitan esta tarea.

El paso de representación y transformación de datos en la metodología de ciencia de datos implica comprender y evaluar la calidad de los datos, así como descubrir ideas iniciales. Los científicos de datos actúan como detectives, utilizando diversas técnicas y herramientas para mejorar la representación de los datos. Una de las principales herramientas es la estadística descriptiva, que permite resumir cuantitativamente un conjunto de datos y responder preguntas clave sobre su comportamiento. A través de medidas como el número total de observaciones, promedio, mediana, modo, mínimo, máximo y desviación estándar, los científicos de datos pueden obtener una visión clara y rápida de los datos que están analizando.

Por ejemplo, la siguiente tabla indica el ingreso familiar promedio en dólares estadounidenses para los clientes de un negocio, en función de su nivel de educación. Los datos son ficticios y con fines ilustrativos.

	No completó la escuela secundaria	Título de escuela secundaria	Alguna universidad	Título universitario
Significado	51.48	52	56.90	70.94
Desviación estándar	51.855	56.370	53.836	67.940
N	246	527	333	310
Mediana	36.00	35.00	39.00	49.00
Mínimo	15	12	13	15
Máximo	497	533	403	512

La representación de datos es seguida por la transformación de datos, donde los científicos de datos organizan la información en un formato adecuado para modelos de aprendizaje automático, que solo procesan números. Para ello, pueden transformar datos no estructurados en representaciones numéricas, como a través de la tokenización, que convierte texto en elementos significativos. Además, utilizan herramientas y lenguajes como Python para realizar análisis más profundos y crear visualizaciones complejas, facilitando la identificación de los modelos más adecuados para los datos analizados.

La visualización de datos es importante ya que puede comunicar información compleja de manera clara y efectiva. Para una presentación de datos exitosa, es crucial considerar varios aspectos: el propósito de la visualización y cómo aborda un problema específico, la audiencia a la que va dirigida y su relevancia, la representación adecuada de los datos y la posibilidad de futuras actualizaciones, así como el contexto en el que se presentará (software, sitio web, informe, etc.). En última instancia, la visualización debe responder a un problema comercial actual y proponer una solución al patrocinador.

Un modelo de datos es una representación que identifica datos, atributos y relaciones, proporcionando una visión generalizada del escenario y los datos comerciales. Construir un modelo permite a los científicos de datos abordar problemas comerciales de manera sistemática, mejorando las predicciones y la comprensión del sistema en cuestión. Utilizando el método científico, los científicos de datos experimentan con diferentes tipos de modelos y los entrenan mediante aprendizaje automático, que enseña a las computadoras a resolver problemas sin necesidad de programación explícita. A través de algoritmos de aprendizaje automático, las máquinas pueden aprender de los datos y mejorar su precisión con el tiempo.

Aquí hay una tabla para una comparación rápida del aprendizaje supervisado y el aprendizaje no supervisado.

	Aprendizaje supervisado	Aprendizaje no supervisado
Proceso	Se dan variables de entrada y salida	Solo se proporcionan datos de entrada
Datos de entrada	Los algoritmos se entrenan usando datos etiquetados	Los algoritmos se usan contra datos que no están etiquetados
Complejidad	Método más simple	Computacionalmente complejo
Uso de datos	Utiliza datos de entrenamiento para identificar un enlace entre la entrada y las salidas	No utiliza datos de salida
Precisión de los resultados	Método altamente preciso y confiable	Método menos preciso y confiable
Ejemplos de dónde se usa	Detección de fraude, clasificación de imágenes, pronóstico del tiempo, pronóstico del mercado y estimación de la esperanza de vida	Segmentación de clientes, marketing dirigido, comprensión significativa y sistemas que recomiendan música o transmisión de películas

Un modelo de regresión es un modelo popular de ciencia de datos. Los modelos de regresión estiman la probabilidad de que ocurra un evento o una variable categórica, en función de un

conjunto de datos dado de variables independientes. Dado que el resultado es una probabilidad, la variable categórica puede ser verdadera o falsa, sí o no, 1 o 0, voto votado o no, y así sucesivamente.

La implementación de un modelo de aprendizaje automático es el proceso de integrar el modelo en un entorno de producción empresarial, utilizando herramientas y software seleccionados por la compañía. Una vez implementado, el modelo puede generar predicciones continuas para futuras soluciones. Además, debe ser mantenido y supervisado por un científico de datos para asegurar su correcto funcionamiento a lo largo del tiempo.

La ciencia de datos ha transformado la interpretación y uso de datos en diversas industrias, como atención médica, banca y comercio electrónico. Empresas como Amazon, Google y Facebook aplican estos conceptos para obtener información valiosa y tomar decisiones estratégicas.

Predicción de enfermedades y personalización de recomendaciones en salud.

Optimización de rutas de envío en tiempo real.

Evaluación del rendimiento de atletas.

Prevención de evasión fiscal y predicción de encarcelamiento.


Automatización de anuncios digitales en comercio electrónico.

Mejora de experiencias en videojuegos.

Creación de algoritmos para identificar parejas en redes sociales.

En un equipo de ciencia de datos, todos los miembros son responsables de comprender el problema comercial para proponer soluciones efectivas. Las organizaciones utilizan diversos títulos para roles relacionados con datos, y en función del tamaño de la empresa, una persona puede asumir múltiples responsabilidades.

Un ejemplo de un rol no técnico es el de periodista de datos, quien se centra en comunicar resultados de manera efectiva. Este profesional convierte hechos en narrativas convincentes, utilizando visualizaciones de datos para transmitir ideas de forma clara y atractiva.



El software de código abierto es un tipo de software cuyo código fuente es accesible públicamente, permitiendo a cualquier persona usar, ver, modificar y compartirlo. Se basa en una comunidad colaborativa donde los desarrolladores contribuyen ideas y mejoras. Los términos clave en este ámbito incluyen "comunidad", que se refiere a todos los involucrados en un proyecto colaborador quien aporta al proyecto committer que revisa y aprueba cambios en el código código de conducta que establece pautas de comportamiento aceptable y "directrices de contribución que detallan cómo participar en el proyecto. Estos elementos son fundamentales para fomentar un entorno de colaboración y respeto en el desarrollo de software de código abierto

El software de código abierto es fundamental para científicos e ingenieros de datos, ya que ofrece acceso a tecnologías clave y oportunidades para aprender y desarrollar habilidades. Las comunidades de código abierto sirven como recursos de tutoría, permiten a los desarrolladores mostrar su experiencia y ayudan a quienes inician su carrera en programación. Desde la perspectiva empresarial, el software de código abierto fomenta la innovación al aprovechar el modelo comunitario, reduce costos al facilitar el desarrollo y la corrección de errores, y permite a las empresas influir en el desarrollo tecnológico. Además, contribuye a mejorar la seguridad y confiabilidad del software, ayudando a las empresas a mantenerse competitivas

En GitHub, puedes crear y dejar tu propio proyecto de código abierto en un repositorio, que almacena archivos y datos. También puedes contribuir a proyectos existentes al acceder a su repositorio, realizar actualizaciones y solicitar revisiones de tus cambios.

Microsoft Excel aplicación de hoja de cálculo de Microsoft utilizada para el análisis de datos. Permite ingresar, examinar y manipular datos en filas y columnas, así como limpiar la información antes del análisis. Excel cuenta con funciones integradas para el análisis de datos, como filtrado, fórmulas y tablas de pivote, y ofrece diversas opciones de visualización, incluyendo gráficos de pastel, barra, línea y diagrama de dispersión. Además, proporciona plantillas y recomendaciones para crear gráficos basados en los datos, permitiendo combinar diferentes tipos de gráficos en una misma hoja de cálculo.

Google Sheets es una herramienta gratis que permite ingresar, analizar y visualizar datos para tomar decisiones basadas en información Sheets ofrece características como la entrada de datos y la capacidad de insertar gráficos, como gráficos de líneas, para visualizar la información. Un ejemplo de Google Sheets muestra datos de descarga de vídeo, destacando las similitudes en las funcionalidades de ambas aplicaciones de hoja de cálculo.

SQL, o Structured Query Language, es un lenguaje estándar utilizado para comunicarse con bases de datos relacionales SQL permite realizar consultas y modificar el contenido de una base de datos, facilitando operaciones como seleccionar, recuperar, actualizar y eliminar datos. Los comandos SQL más comunes incluyen Select, Insert, Update, Delete, Create y Drop. Con SQL, puedes ejecutar consultas, gestionar registros, crear nuevas bases de datos y tablas, establecer permisos y crear procedimientos almacenados y vistas.

Tómese un momento para revisar un ejemplo SQL

Aquí hay una base de datos de muestra de datos de empleados para una empresa de tecnología en los Estados Unidos.

Primero	Último	ID	Edad	Ciudad	Estado
Mike	Jonas	99001	47	Sacramento	California
Santosh	Mohan	99102	26	San Diego	California
Julie	Smith	88323	39	San Diego	California
Lisa	Avis	88678	31	San José	California
Juan	Cho	99544	40	Alto Palo	California
Maya	Rodriguez	934029	24	Alto Palo	California

Recuerde la tabla de datos de empleados anterior. Cómo puede seleccionar solo **empleados cuyos apellidos terminan con una “s”**?

- **Como** es un operador que le permite seleccionar solo filas que son “como” lo que especifica.
- Puedes usar el **signo de porcentaje (%)** como “comodín” para que coincida con cualquier carácter posible que pueda aparecer antes o después de los caracteres especificados.

Entonces, aquí está el **Seleccionar** declaración para extraer los datos deseados:


```
seleccione primero, último  
de empinfo  
donde último COMO '%s';
```

Con esa declaración, recuperaría los datos de los empleados de Mike Jonas y Lisa Adams ya que sus apellidos terminan con una “s”.

NoSQL, que significa no solo SQL, es un tipo de base de datos que permite trabajar con datos no estructurados en bases de datos no relacionales. Es útil para big data y aplicaciones web en tiempo real, como las que maneja Twitter. Los científicos de datos utilizan NoSQL para almacenar datos no estructurados, como imágenes y texto. Los tipos de bases de datos NoSQL incluyen bases de datos de documentos, de columnas amplias y de gráficos, complementando el uso de SQL en la gestión de datos.

Python es un lenguaje de programación gratuito, de código abierto y de propósito general. Diseñado para ser fácil de usar, Python se destaca por su sintaxis legible y su uso de espacios en blanco. Es versátil y se puede utilizar para desarrollar aplicaciones web y proyectos de ciencia de datos, así como para conectarse a bases de datos y manipular archivos. Python es capaz de manejar big data y realizar cálculos complejos, y se puede combinar con bibliotecas como pandas para el análisis y visualización de datos.

IBM Watson Studio es un entorno de desarrollo integrado (IDE) que combina herramientas de desarrollo y analítica en una plataforma colaborativa para ciencia de datos y aprendizaje automático. Diseñado para ser accesible, no requiere conocimientos de codificación y funciona con herramientas de código abierto. Incluye una herramienta de refinación de datos que permite preparar y transformar grandes volúmenes de datos en información de alta calidad. Además, ofrece capacidades de visualización mediante gráficos integrados y permite programar trabajos para obtener resultados repetibles.




Laboratorio 5: Preparación de datos con Refinería de datos

Medios Relacionados



Tableau es un popular software de visualización de datos e inteligencia empresarial que permite a las empresas extraer información significativa de grandes volúmenes de datos. Con Tableau los usuarios pueden crear paneles, gráficos, mapas y más para facilitar la toma de decisiones comerciales, todo sin necesidad de experiencia en programación, gracias a su interfaz intuitiva. Además, permite diseñar visualizaciones interactivas que mejoran la comprensión de los datos.



Matplotlib es una de las bibliotecas más utilizadas en Python para crear gráficos bidimensionales a partir de datos en listas o matrices. es un proyecto de código abierto mantenido por la comunidad. Con Matplotlib, es posible generar gráficos visuales con solo unas pocas líneas de código, creando diferentes tipos de visualizaciones, como diagramas de dispersión, histogramas y gráficos de barras. Las visualizaciones pueden ser estáticas, animadas o interactivas, y se pueden exportar a varios formatos de archivo.

Tómese un momento para revisar un ejemplo de Matplotlib

Aquí hay un ejemplo de un script para crear un gráfico de barras agrupado. El script incluye etiquetar las barras.

Estudie el siguiente script de Matplotlib y luego revele el gráfico.

```
import matplotlib.pyplot as plt
import numpy as np

etiquetas = ['G1', 'G2', 'G3', 'G4', 'G5']
men_significa = [20, 34, 30, 35, 27]
women_significa = [25, 32, 34, 20, 25]

x = np.arange(len(etiquetas)) # las ubicaciones de las etiquetas
ancho = 0.35 # el ancho de las barras

higo, hacha = plt.subplots()
rects1 = ax.bar(x - width/2, men_means, width, label='Men')
rects2 = ax.bar(x + width/2, women_means, width, label='Women')

# Agregue un poco de texto para etiquetas, título y etiquetas de tick de x-axis
ax.set_ylabel('Puntuaciones')
ax.set_title('Puntuaciones por grupo y sexo')
ax.set_xticks(x, etiquetas)
ax.legend()



ax.bar_label(rects1, padding=3)
ax.bar_label(rects2, padding=3)

fig.tight_layout()

plt.show()
```

Al elegir herramientas de análisis y visualización de datos, las empresas deben considerar varios factores, como el tipo de datos a analizar, la necesidad de procesos específicos como el modelado de datos, el volumen de datos si es big data el tipo de visualizaciones requeridas (interactivas o no), el nivel de tecnicidad necesario para los roles que utilizarán las herramientas (científicos de datos o profesionales de marketing) y el presupuesto disponible. Seleccionar las herramientas adecuadas es crucial para satisfacer las necesidades de la empresa en el momento oportuno.

No todas las herramientas son adecuadas para todos los usuarios o proyectos, ya que cada una tiene características específicas. Se presenta una visualización que ilustra la correlación entre la flexibilidad de una herramienta y la dificultad de aprendizaje para principiantes, destacando que algunas herramientas pueden ser familiares mientras que otras pueden ser nuevas para el usuario.



IBM Watson Studio es un entorno de desarrollo integrado IDE diseñado para simplificar proyectos de ciencia de datos y aprendizaje automático. Ofrece un proceso simplificado para extraer información de los datos permitiendo a las empresas ser más inteligentes más rápido con herramientas colaborativas, visualizaciones fáciles de crear y acceso a tecnologías de código abierto, IBM Watson Studio permite a los científicos de datos desarrollar, entrenar, gestionar e implementar aplicaciones impulsadas por inteligencia artificial en un solo lugar facilitando la


Visualiza datos para descubrir ideas

[illegible]

Tu Futuro en Datos: Panorama Laboral

COMENZAR CURSO

IBM SkillsBuild



En este curso, aprenderá sobre el mercado laboral de los datos y sus proyecciones, las responsabilidades y competencias de un analista de datos y de un científico de datos, y los recursos y oportunidades de aprendizaje que puede explorar.

Seleccione **COMENZAR CURSO** para comenzar o consulte aquí el contenido detallado del curso.

El sector de los datos está en auge, convirtiéndose en una necesidad esencial para las empresas, más allá de ser solo una tendencia. Las competencias y puestos relacionados con el análisis y la ciencia de datos son altamente demandados en el mercado laboral global, con un crecimiento constante en la necesidad de profesionales especializados. Aunque existen diferencias entre las funciones de un analista de datos y un científico de datos, ambas áreas están experimentando un rápido aumento en la demanda.

El análisis de datos, aunque es un concepto relativamente nuevo ya se utiliza en sectores como la atención sanitaria, donde ayuda a predecir resultados de pacientes y mejorar la asignación de recursos. Además, el análisis predictivo se aplica en dispositivos del Internet de las Cosas (para anticipar comportamientos y automatizar hogares. Asistentes virtuales como Google Search y Alexa utilizan procesamiento del lenguaje natural para interactuar con los usuarios, y su combinación con inteligencia artificial puede abordar desafíos globales. En general el análisis de datos transformará los procesos empresariales, ofreciendo a los profesionales del sector oportunidades de crecimiento y una carrera segura en un futuro prometedor.

Los datos ayudan a todas las industrias

En general, los profesionales de los datos trabajan en todos los sectores. Los encontrará en grandes empresas mundiales y en empresas de tamaño medio de todos los sectores, como:

Finanzas

Seguros

Asistencia médica

Servicios científicos

Tecnología de la información (TI)

Marketing

Gestión de empresas

Fabricación

Administración pública

Servicios educativos

Arte y entretenimiento

Distribución

La responsabilidad de un analista de datos es recopilar, depurar y analizar datos para identificar tendencias, patrones y hacer pronósticos se enfocan en problemas empresariales específicos planteados por la dirección o científicos de datos, como la alta incidencia de defectos en un equipo. Tras analizar los datos los analistas presentan sus conclusiones al equipo del proyecto y a la dirección mediante visualizaciones, como gráficos y diagramas, facilitando así la toma de decisiones y la implementación de acciones.

El trabajo de un científico de datos se enfoca en utilizar estadísticas, algoritmos de aprendizaje automático y programación para extraer y analizar datos relevantes. Su principal responsabilidad es formular y probar hipótesis que ayudan a las empresas a tomar decisiones informadas y predecir resultados futuros. Colaboran con analistas de datos para recopilar y depurar grandes volúmenes de datos incluyendo datos no estructurados como imágenes y texto.

Las empresas que buscan mejorar la toma de decisiones, optimizar la experiencia del cliente y resolver problemas empresariales necesitan profesionales cualificados. Según Burning Glass Technologies, las competencias clave para analistas y científicos de datos son esenciales para satisfacer estas necesidades.

Lenguajes y herramientas muy utilizados en el análisis de datos

En esta tabla se destacan algunas herramientas y lenguajes de programación de análisis de datos muy utilizados. Dado que estas herramientas y lenguajes de programación se suelen utilizar en el análisis de datos, es importante que conozca al menos algunos de ellos si quiere desarrollar su carrera profesional en el campo de los datos.

Herramienta	Finalidad
SQL	SQL (Structured Query Language) es un lenguaje de programación específico para la gestión de datos en sistemas de gestión de bases de datos relacionales
Microsoft Excel	Una sencilla pero potente herramienta de hoja de cálculo para recopilar y analizar datos
Python	Inicialmente se diseñó como lenguaje de programación orientado a objetos (POO) para el desarrollo de software y web, y posteriormente se ha mejorado para adaptarlo a la ciencia de datos
R	Lenguaje de programación para modelización estadística, visualización y análisis de datos
SAS	Paquete de software estadístico muy utilizado para Business Intelligence (BI), gestión de datos y análisis predictivo
Microsoft Power BI	Una solución de análisis empresarial de Microsoft que está disponible en tres versiones: Desktop, Pro y Premium
Tableau	Una herramienta de BI desarrollada para que los analistas de datos visualicen, analicen y comprendan los datos
Apache Spark	Un motor de análisis integrado para el procesamiento de big data, diseñado para desarrolladores, investigadores y científicos de datos
Google Analytics	Un servicio de análisis web que rastrea e informa sobre el tráfico del sitio web
IBM Watson Studio	Un entorno de desarrollo interactivo (IDE) que proporciona acceso a herramientas para analizar y visualizar datos, depurar y dar forma a los datos, ingerir datos en flujo o crear y entrenar modelos de aprendizaje automático

Fuente: *What Is Data Analytics?*, CompTIA, Inc., <https://www.comptia.org/content/guides/what-is-data-analytics>.

Los nombres de los puestos en el campo de la inteligencia artificial no son homogéneos, y una oferta de analista de datos puede incluir competencias de un científico de datos. Términos como ingeniero de datos, analista de empresa y periodista de datos son comunes. Los empresarios buscan no solo habilidades de análisis de datos, sino también conocimientos específicos del sector, como en salud o informática. Además, las competencias laborales, como la comunicación y el trabajo en equipo, son esenciales, ya que los proyectos de ciencia de datos suelen requerir colaboración para resolver problemas reales. Por lo tanto, se valora una combinación de habilidades técnicas y competencias interpersonales.


La curiosidad es importante para entender problemas empresariales y trabajar con datos. Es importante adoptar una postura y confiar en ella, pero también ser flexible y adaptable, ya que el análisis de datos puede llevar a modificar hipótesis iniciales además, la capacidad de contar historias es crucial para comunicar las conclusiones de manera efectiva, asegurando que los hallazgos sean comprendidos y valorados

El camino para convertirse en un profesional de datos varía según la persona, pero hay estrategias generales a seguir. Primero, amplíe sus conocimientos sobre análisis de datos, estadísticas e inteligencia artificial, investigando áreas de interés y proyectos impactantes. Segundo, continúo aprendiendo a través de recursos en línea y cursos para correr con los requisitos de formación necesarios. Por último, explore el mercado laboral revisando ofertas de empleo para identificar cualificaciones comunes y trabajos atractivos, y trabajo para cumplir con esos requisitos.

The screenshot shows a web browser displaying a course completion interface. The browser's address bar shows the URL: `ole03.yourlearning.ibm.com/mod/scorm/player.php?cat=fe40394716012c1040ecc41af60f0948a=1140¤torg=articulate_rise&scoid=3809&display=popup&...`. The page title is "Tu Futuro en Datos: Panorama Laboral". A progress bar indicates "96% COMPLETA". The left sidebar lists the course structure:

- MÓDULO 4: RECURSOS ÚTILES Y GUÍA DE INICIO
 - Acerca de este módulo (checked)
 - Recursos que explorar (checked)
 - Primeros pasos en el campo (checked)
- RESUMEN Y EVALUACIÓN FINAL
 - ¡Ha llegado muy lejos! (checked)
 - Principales puntos que recordar (checked)
 - Evaluación final (checked)
 - Finalización del curso (in progress)

The main content area features a large circular progress indicator with a blue checkmark in the center. The text "Tu calificación 80%" is displayed inside the circle. To the right of the circle, the text "APROBADO 80%" is shown. Below the circle, there is a button labeled "INTENTAR DE NUEVO" with a circular arrow icon. At the bottom, there is a large blue button labeled "Continuar".



IBM SkillsBuild

Recomendaciones ▾ Pro



Plan de formación

Data Fundamentals (Earn a credential!)

⌚ Aproximadamente 7 horas 🏠 2.358 ★★★★★ 110

✓ 12 Mar 2025 de realización 100% 8 realizadas de 8 obligatorias [Mostrar más](#)


▼

✓
Credly account information
Finalizado

✓
Courses
Finalizado

✓
Credential information
Finalizado

▼



Realice las 2 actividades obligatorias



Guidance

Cree una cuenta de Credly

5 minutos

✓ Finalizado 12 Mar 2025



Video

Earn it! Accept it! Share it! | IBM SkillsBuild

3 minutos

✓ Finalizado 12 Mar 2025

Courses

✓ Finalizado

Realice las 5 actividades obligatorias



eLearning

Introduction to Data Concepts

1 hora 15 minutos

✓ Finalizado 12 Mar 2025



eLearning

Data Science in Our World

2 horas

✓ Finalizado 12 Mar 2025



eLearning

Overview of Data Tools and Languages

1 hora 30 minutos

✓ Finalizado 12 Mar 2025



eLearning

Clean, Refine, and Visualize Data with IB...

1 hora 35 minutos

✓ Finalizado 12 Mar 2025



eLearning

Tu Futuro en Datos: Panorama Laboral

50 minutos

✓ Finalizado 12 Mar 2025

<https://students.yourlearning.ibm.com/activity/URL-4D23375097DA?planId=PLAN-0EC2BCE...>